HSE: specyfikacja dla agenta kodującego

Wersja 0.1. Zakres: symulator i rdzeń. Orkiestrator na modelach lokalnych dopiero po pozytywnym wyniku symulatora.

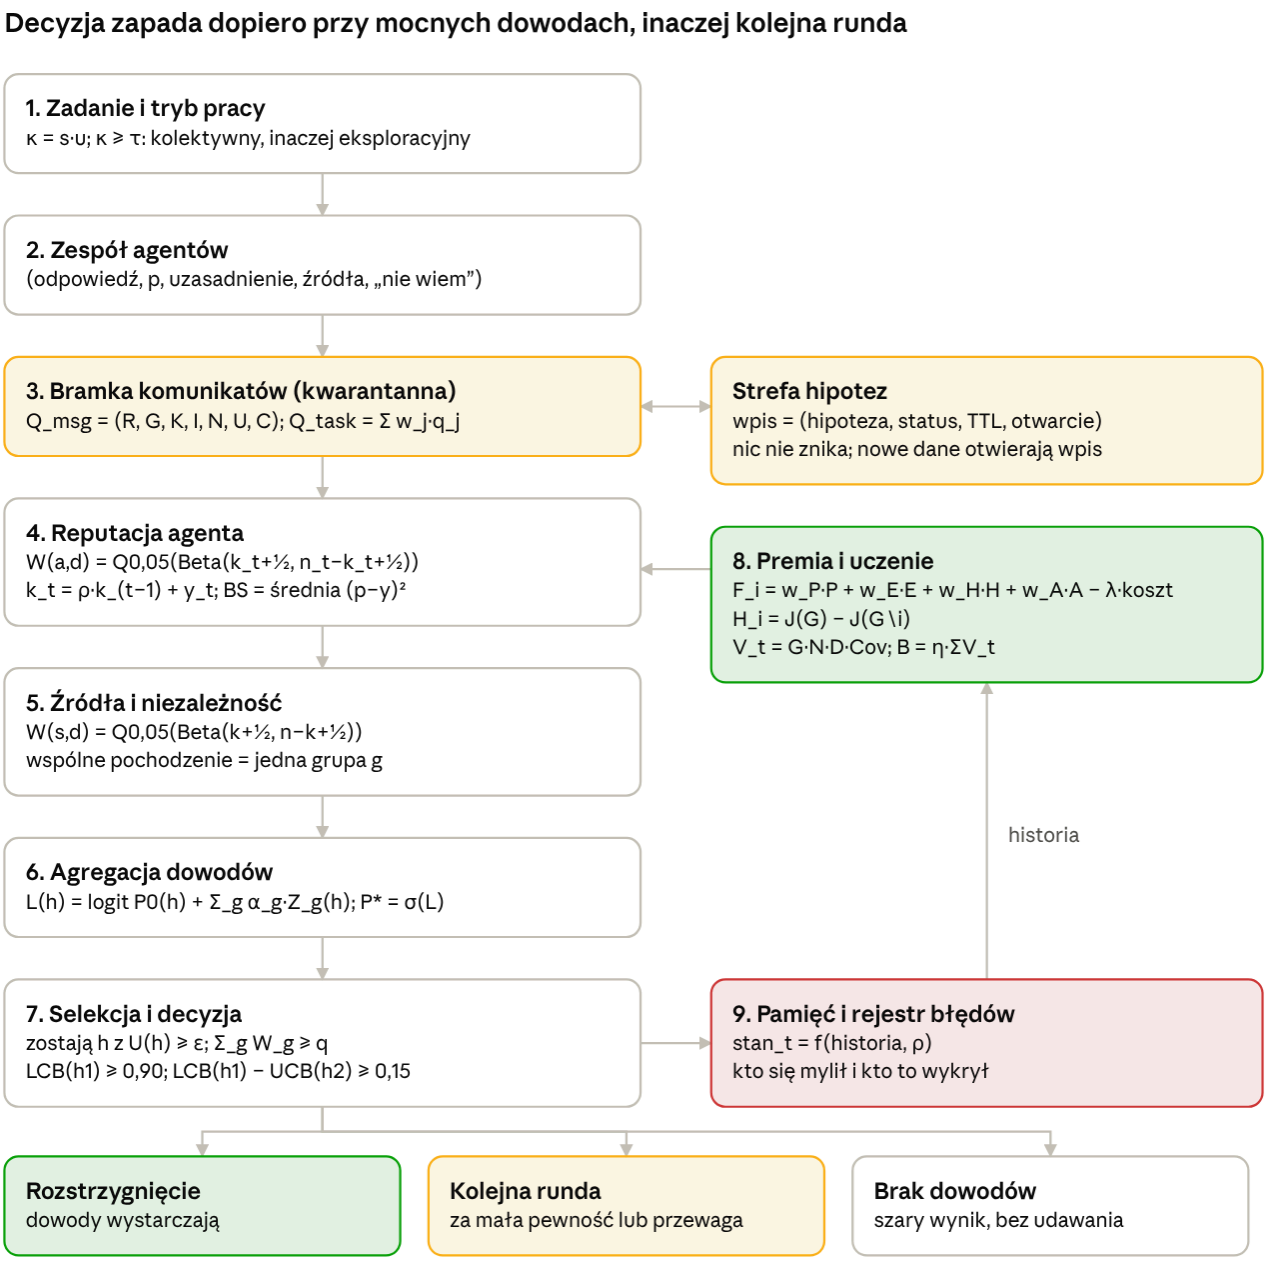
Ten dokument zbiera całość projektu w jednym miejscu: ideę, architekturę, zasady, specyfikację v0.1 i plan dalszych etapów.

Idea w skrócie

Projekt buduje adaptacyjny ekosystem komunikacji i współpracy bytów cyfrowych, czyli agentów AI. Liczy się w nim jakość przepływu informacji, a nie sama liczba odpowiedzi.

- Problem: filtry, dostrajanie i wspólne dane treningowe mogą zawężać to, co modele uznają za warte rozważenia, a zgodność modeli daje pozór niezależnego potwierdzenia.
- Zasada: kwarantannować wiarygodność informacji, nigdy samą możliwość jej badania. Kwarantanna epistemiczna jest jednym z mechanizmów kontroli jakości przepływu, a nie celem.
- Mechanizm: hierarchiczna selekcja epistemiczna (HSE), czyli reputacja agentów w dziedzinach, selekcja konkurujących hipotez zamiast uśredniania i szary wynik „za mało dowodów” zamiast wymuszonej odpowiedzi.
- Ekosystem: wiedza, komunikacja, adaptacja, ewolucja. Agenci różnią się kompetencjami, a system premiuje tych, którzy poprawiają wyniki innych.

Architektura



zielony: potwierdzenie i premia; żółty: niepewność; czerwony: błędy; strzałki: przepływ

architektura HSE · 9 elementów, 3 możliwe wyniki

Zadanie przechodzi przez zespół agentów, bramkę komunikatów i oceny wiarygodności do selekcji, a wynik wraca do pamięci i reputacji. Wzory elementów są w sekcji Algorytmy pod tymi samymi numerami.

Element	Rola
1. Zadanie i tryb	Ustala stawkę błędu i niepewność, a z nich tryb pracy: kolektywny lub eksploracyjny.

Element	Rola
2. Zespół agentów	Modele z różnych rodzin odpowiadają niezależnie: odpowiedź, pewność p, uzasadnienie, źródła lub „nie wiem”.
3. Bramka komunikatów	Ocenia komunikat w 7 wymiarach i nadaje status. To kwarantanna epistemiczna.
Strefa hipotez	Przechowuje niepotwierdzone pomysły z TTL. Nic nie znika, nowe dane otwierają wpis ponownie.
4. Reputacja agenta	Ostrożna wiarygodność w dziedzinie (dolna granica rozkładu Beta) z zapominaniem i kalibracją Briera.
5. Źródła i niezależność	Ocenia pochodzenie źródeł. Modele o wspólnym pochodzeniu liczą się jako jedna grupa.
6. Agregacja dowodów	Łączy dowody grup w logarytmicznych szansach zamiast średniej.
7. Selekcja i decyzja	Odrzuca słabe hipotezy. Wynik: rozstrzygnięcie, kolejna runda albo brak dowodów.
8. Premia i uczenie	Premiuje wkład w poprawę wyników innych i wartościowe testy, a potem aktualizuje reputację.
9. Pamięć i rejestr błędów	Zapisuje błędy, ich wykrywców i zmiany decyzji. Zasila reputację i pulę testów.

Zasady projektowe

- Hybryda celu i jednostki. Cel nadrzędny to kilka niezmienników: jakość komunikacji, zdolność korygowania błędów, brak zamykania możliwości badania. Zmienia się rzadko i procedurą. Cele lokalne to role wynikające z celu nadrzędnego, a część rund zostaje wolną przestrzenią eksploracji.
- Tryb zależny od stawki. Wysoka stawka lub niska pewność: tryb kolektywny (hierarchia, kworum, niezależna weryfikacja). Eksploracja: tryb indywidualny, bo niezależność błędów jest wtedy wartością. Na eksplorację bez stawki idzie stała część rund.
- Tempo. Kworum zamiast czekania na wszystkich. Późne dowody wchodzą jako nowe i mogą ponownie otworzyć wynik.
- Premia za asystę. Wkład w poprawę innych liczy się kontrfaktycznie i tylko przy potwierdzeniu z zewnątrz. Liczba wiadomości nie jest nagradzana.

- Pamięć. Obecny stan systemu wynika z historii, a zapominanie sprawia, że reputację trzeba utrzymywać.
- Bezpieczeństwo oddzielone od oceny wiedzy. Odmowa działania nie oznacza odmowy zbadania hipotezy. Standardy dowodowe są symetryczne, a pochodzenie informacji jawne.
- Pułapki. Dominacja lidera: jego przywilej dotyczy testów i przydziału zadań, nie wiarygodności odpowiedzi. Testowanie według własnych przekonań: niezależna walidacja klucza, rotacja autorów, ukryte testy. Zgodność nie jest prawdą: liczy się niezależność dowodów, a nie liczba zgodnych agentów. Cel wyłaniany z ogółu wymaga głosów liczonych per grupa niezależna.

Cel

Zbudować rdzeń, który ocenia reputację agentów w dziedzinach, przechowuje komunikaty i hipotezy ze statusami oraz rozstrzyga lub odracza decyzję. Najpierw sprawdzić na agentach syntetycznych, czy wzory działają.

Struktura projektu

- `hse/core/reputation.py` : reputacja, kalibracja, zapominanie
- `hse/core/aggregate.py` : agregacja logitowa z grupami niezależności
- `hse/core/select.py` : selekcja hipotez, kryterium zwycięzcy, kworum
- `hse/core/gate.py` : statusy komunikatów i strefa hipotez
- `hse/core/rewards.py` : H_i, F_i, V_t
- `hse/store.py` : SQLite
- `hse/sim/` : agenci syntetyczni i scenariusze
- `tests/` : testy jednostkowe wzorów

Model danych (SQLite)

Tabela	Pola
agents	id, family, role
trials	id, agent_id, domain, p, correct, ts
messages	id, agent_id, task_id, hypothesis_id, q_vector, status, ts
hypotheses	id, text, status, ttl, reopen_condition, history

Tabela	Pola
errors	id, trial_id, error_type, detected_by, changed_decision

Statusy komunikatu: potwierdzony, hipoteza, sprzeczny, błędny, nowy pomysł. Wpis w strefie hipotez nigdy nie jest usuwany, tylko zmienia status.

Algorytmy

Wzory są numerowane tak jak elementy diagramu. To schemat do skalibrowania na własnych testach, a nie gwarancja prawdy.

1. Tryb pracy

```
\kappa = s \cdot u, \qquad \kappa \ge \tau \Rightarrow \text{tryb kolektywny, w przeciwnym razie eksploracyjny}
```

Gdzie s to stawka błędu, a u niepewność.

3. Jakość komunikatu

```
Q_{msg} = (R, G, K, I, N, U, C), \qquad Q_{task} = \sum_{j=1}^{7} w_j q_j
```

R trafność, G oparcie w źródłach, K kalibracja, I interoperacyjność, N nowość, U użyteczność, C spójność. Wagi w_j zależą od zadania: w faktach większe dla G i K, w zadaniach twórczych dla N i U. W v0.1 używane tylko G, K i C.

4. Reputacja agenta i kalibracja

```
W_{a,d} = Q_{0.05}(\theta), \qquad \theta \sim \mathrm{Beta}\left(k_t + \tfrac{1}{2},\ n_t - k_t + \tfrac{1}{2}\right)
```

```
k_t = \rho k_{t-1} + y_t, \qquad n_t = \rho n_{t-1} + 1, \qquad BS = \frac{1}{n} \sum_{i} (p_i - y_i)^2
```

Reputacja jest liczona osobno dla każdej pary (agent, dziedzina). Domyślnie ρ = 0,98, co daje efektywną próbę około 50 zadań, więc reputację trzeba stale utrzymywać.

5. Źródła i grupy niezależności

```
W_{s,d} = Q_{0.05}\left(\mathrm{Beta}\left(k + \tfrac{1}{2},\ n - k + \tfrac{1}{2}\right)\right)
```

Grupa g to agenci lub źródła o wspólnym pochodzeniu (ta sama rodzina modeli, ten sam materiał pierwotny). Liczą się jako jeden głos.

6. Agregacja dowodów

```
L(h) = \operatorname{logit} P_0(h) + \sum_g \alpha_g Z_g(h), \qquad P^*(h) = \frac{1}{1 + e^{-L(h)}}
```

Przed kalibracją P* jest punktacją, a nie prawdopodobieństwem.

7. Selekcja, zwycięzca i kworum

```
H_{t+1} = \{h \in H_t : U(h) \ge \varepsilon\}
```

```
LCB(h_1) \ge 0.90, \qquad LCB(h_1) - UCB(h_2) \ge 0.15, \qquad \sum_g W_g \ge q
```

Bez spełnienia warunków wynik to „kolejna runda” albo „brak dowodów”. Późny dowód może ponownie otworzyć decyzję.

8. Wkład, użyteczność i wartość testu

```
H_i = J(G) - J(G \setminus i), \qquad F_i = w_P P_i + w_E E_i + w_H H_i + w_A A_i - \lambda \cdot \mathrm{koszt}_i
```

```
V_t = G_t N_t D_t \mathrm{Cov}_t, \qquad B_m = \eta \sum_t V_t
```

Premia H_i liczy się tylko przy potwierdzeniu z zewnątrz. Bonus B_m daje przywileje organizacyjne, nigdy wyższe P* dla odpowiedzi autora testu. Nie nagradzać liczby wiadomości.

Definicje domyślne v0.1

Symbol	Definicja domyślna
Z_g(h)	logit skalibrowanego p, uśredniony po agentach grupy g z wagami W; kalibracja regresją logistyczną na zbiorze kalibracyjnym
α_g	1 na starcie; później uczone na ukrytych testach, nigdy według popularności modelu
P_0(h)	stały prior, równy dla wszystkich hipotez

Symbol	Definicja domyślna
LCB, UCB	5. i 95. percentyl P*(h) z bootstrapu po grupach g
J(G)	odsetek poprawnych rozstrzygnięć grupy na zadaniach z kluczem; H_i liczone metodą leave-one-out
s, υ	w symulatorze parametry scenariusza; w orkiestratorze s z typu zadania, υ = 1 − max P*(h) po pierwszej rundzie
τ, ε, q	ustawienia startowe do strojenia: τ = 0,25, ε = 0,05, q = 60% sumy wag
G_t, N_t, D_t, Cov_t	G: potwierdzenie klucza przez niezależnego weryfikatora (0–1); N: 1 − największe podobieństwo do istniejących testów; D: różnica trafności najlepszego i najsłabszego agenta na teście; Cov: 1/(1 + n_d/10), gdzie n_d to liczba testów w dziedzinie

Symulator

Agenci syntetyczni mają znaną skuteczność i kalibrację. Parametry: liczba agentów, liczba rodzin, korelacja błędów w rodzinie, współczynnik pewności, opóźnienie odpowiedzi.

Scenariusze do uruchomienia:

1. Bazowy: czy W zbiega do prawdziwej skuteczności agentów.
2. Skorelowane błędy: czy grupy g chronią przed pozornym konsensusem.
3. Agent nadmiernie pewny siebie: czy Brier obniża jego wagę.
4. Nadużycie premii za asystę: agenci wzajemnie potwierdzają się bez klucza. Premia ma nie rosnąć.
5. Tempo: kworum a czekanie na wszystkich przy agentach o różnej szybkości.
6. Późne dowody: czy decyzja poprawnie się otwiera ponownie.

Kryteria akceptacji

- Wszystkie wzory mają testy jednostkowe na przykładach liczbowych.
- W scenariuszu 2 dokładność z grupami g jest wyższa niż przy zwykłej średniej.
- W scenariuszu 4 premia H_i bez potwierdzenia zewnętrznego jest równa zero.

- W scenariuszu 5 kworum skraca czas decyzji bez spadku dokładności poniżej ustalonego progu.
- Wyniki zapisują się do rejestru błędów i da się je odtworzyć z ziarna losowości.

Poza zakresem v0.1

Wektor Q_msg w pełnych 7 wymiarach (na start tylko G, K, C), ewolucja protokołów, wyłanianie celu nadrzędnego, panel graficzny.

Krok następny: orkiestrator lokalny

Ten sam rdzeń, ale zamiast agentów syntetycznych adapter modelu.

- Środowisko: lokalny serwer LM Studio zgodny z API OpenAI, dwa lub trzy modele z różnych rodzin, ładowane kolejno z powodu limitu VRAM.
- Interfejs: `ask(task) -> Answer`, gdzie Answer to JSON z polami `answer`, `p`, `reasoning`, `sources`, `abstain`. Błędny JSON: jedno ponowienie, potem odpowiedź liczy się jako „nie wiem”.
- Zadania: pula z kluczem odpowiedzi (fakty, logika, wykrywanie sprzeczności, zmiana sformułowania, nowe dowody), podzielona na kalibracyjne, kontrolne i generowane po niezależnej walidacji.
- Przebieg rundy: szybka ścieżka jednego agenta; kolejni agenci i weryfikacja tylko przy niejednoznacznym wyniku, potem bramka, agregacja, selekcja i zapis do rejestru.
- Pomiary: czas rundy, liczba wywołań modelu, dokładność, Brier Score, odsetek „nie wiem” na zadaniach bez rozwiązania.
- Kryterium przejścia dalej: na zbiorze kontrolnym HSE ma wyższą dokładność niż najlepszy pojedynczy model i niż głosowanie większościowe.

Plan etapów

1. v0.1, symulator i rdzeń. Dalej, gdy spełnione są kryteria akceptacji.
2. v0.2, orkiestrator lokalny. Dalej, gdy HSE przewyższa głosowanie większościowe na zbiorze kontrolnym.
3. v0.3, ewolucja testów i premia za asystę. Lider tworzy testy z niezależną walidacją klucza, a H_i działa na realnych agentach.
4. v0.4, pełny wektor Q_msg i role agentów. Siedem wymiarów jakości i dobór agentów według profilu mocnych stron.
5. v0.5, cel nadrzędny i tryby pracy. Przełączanie trybu kolektywnego i eksploracyjnego, budżet eksploracji, wyłanianie celu z historii z głosami per grupa niezależna.

6. v0.6, panel graficzny. Mapa kompetencji, strefa hipotez i przepływ komunikatów.

Ryzyka i zabezpieczenia

Ryzyko	Zabezpieczenie
Zbyt wiele parametrów bez prawdziwych kluczy odpowiedzi	Start z minimum: reputacja, strefa hipotez, H_i. Reszta po wynikach symulatora.
Nadużycie premii za asystę	Liczona tylko przy potwierdzeniu z zewnątrz; sprawdza ją scenariusz 4 symulatora.
Dominacja lidera	Przywilej dotyczy testów i przydziału zadań. Rotacja autorów i ukryte testy.
Pozorny konsensus	Grupy niezależności α_g i modele z różnych rodzin.
Nieskalibrowana agregacja	P* traktowane jako punktacja, dopóki kalibracja na ukrytych testach tego nie potwierdzi.
Brak klucza w dziedzinach spornych	Bez udawania jednej odpowiedzi: wynik „brak dowodów” albo kilka dobrze uzasadnionych hipotez.
Czas rundy na jednym GPU	Szybka ścieżka najpierw, głębsza weryfikacja tylko przy niejednoznaczności, kworum.

Oznaczenia

Symbol	Znaczenie
s, υ, κ, τ	stawka błędu, niepewność, ich iloczyn, próg trybu kolektywnego
p, y	deklarowana pewność agenta, wynik (1 poprawny, 0 błędny)
k_t, n_t, ρ	ważona liczba sukcesów i prób, współczynnik zapominania
W	ostrożna wiarygodność (5. percentyl rozkładu Beta) agenta a lub źródła s w dziedzinie d

Symbol	Znaczenie
BS	Brier Score, kalibracja pewności
Q_msg, Q_task	wektor jakości komunikatu, ocena zbiorcza dla zadania
g, α_g, Z_g	grupa niezależności, jej współczynnik, jej wkład dowodowy
L, P*	logarytmiczne szanse hipotezy, skalibrowana ocena
U, LCB, UCB, ε, q	górna granica hipotezy, dolna i górna granica P*, próg odrzucenia, kworum
H_i, J, F_i	wkład agenta w grupę, jakość grupy, użyteczność agenta
w_P, w_E, w_H, w_A, λ	wagi użyteczności i kara za koszt
V_t, G, N, D, Cov, η	wartość testu: wiarygodność klucza, nowość, rozróżnialność, pokrycie, współczynnik bonusu